

Actividad 1 - Selección y análisis inicial del corpus

Integrantes: Sergio Soler - Joel Montenegro - Kinan El Halabi

1. Corpus seleccionado:

Optamos por usar el siguiente dataset ubicado en Kaggle ([Amazon Fine Food Reviews](#)) dado que contiene con una variedad de registros, superando las 500.000 filas, siendo la opción candidata para el proyecto.

2. Análisis inicial:

2.1. Origen

El corpus fue recopilado por Julian McAuley y Jure Leskovec, su origen académico es el artículo:

J. McAuley y J. Leskovec. *From amateurs to connoisseurs: modeling the evolution of user expertise through online reviews*. Proceedings of the 22nd International Conference on World Wide Web (WWW), 2013.

La versión distribuida en Kaggle es una republicación del mismo corpus realizada por la propia cuenta del Stanford Network Analysis Project, en la que el fichero de texto plano original se ha convertido a formato tabular.

2.2. Estructura

La tabla consta de 10 columnas.

Campo	Descripción
Id	Identificador de fila
ProductId	Identificador único del producto
UserId	Identificador único del usuario
ProfileName	Nombre de perfil del usuario
HelpfulnessNumerator	Número de usuarios que consideraron útil la reseña
HelpfulnessDenominator	Número de usuarios que valoraron la utilidad de la reseña (a favor o en contra)
Score	Valoración del producto entre 1 y 5
Time	Marca temporal de la reseña (Unix timestamp)
Summary	Resumen breve de la reseña redactado por el usuario
Text	Cuerpo completo de la reseña

2.3. Características estadísticas básicas

2.3.1. Cifras del corpus

Métrica	Valor
Número de reseñas	568.454
Número de usuarios	256.059
Número de productos	74.258
Usuarios con más de 50 reseñas	260
Mediana de palabras por reseña	56
Período cubierto	Octubre 1999 – Octubre 2012
Total de palabras en el corpus (con limpieza básica)	45.427.054
Total de palabras únicas en el corpus (con limpieza básica)	240.772

2.4. Fuentes

Recurso	Referencia
Distribución utilizada (Kaggle)	<i>Amazon Fine Food Reviews</i> , Stanford Network Analysis Project. https://www.kaggle.com/datasets/snap/amazon-fine-food-reviews

2.5. Tamaño

2.5.1. Tamaño en registros

568 454 documentos cada uno con 10 atributos

2.5.2. Tamaño en disco

El archivo Reviews.csv ocupa un total de 286.97 MB en disco

2.6. Vocabulario

Encontramos 45.427.054 palabras en el corpus tras realizar una limpieza básica, aun no se lematiza, no se quitaron las stopwords, ni se implementó stemming.

Solo 240.772 palabras son únicas en el corpus, dándonos que solo el 0.53% de las palabras del corpus es única, teniendo sentido ya que todas las reseñas usan un lenguaje similar al estar en un contexto similar.

Para cumplir con el criterio de la actividad 1, donde permitía que el número de páginas del PDF debe de ser máximo 2, sentimos que este reporte puede llegar a quedar corto de mucha información esencial, por lo que adjunto a la entrega está otro PDF, con el mismo objetivo que este documento, pero teniendo en cuenta más apartados profundos del reporte del corpus.