

Actividad 1 - Selección y análisis inicial del corpus

Integrantes: Sergio Soler - Joel Montenegro - Kinan El Halabi

1. Corpus seleccionado:

Optamos por usar el siguiente dataset ubicado en Kaggle ([Amazon Fine Food Reviews](#)) dado que contiene con una variedad de registros, superando las 500.000 filas, siendo la opción candidata para el proyecto.

2. Análisis inicial:

2.1. Origen

El corpus fue recopilado por Julian McAuley y Jure Leskovec, su origen académico es el artículo:

J. McAuley y J. Leskovec. *From amateurs to connoisseurs: modeling the evolution of user expertise through online reviews*. Proceedings of the 22nd International Conference on World Wide Web (WWW), 2013.

La versión distribuida en Kaggle es una republicación del mismo corpus realizada por la propia cuenta del Stanford Network Analysis Project, en la que el fichero de texto plano original se ha convertido a formato tabular.

2.2. Estructura

La tabla consta de 10 columnas.

Campo	Descripción
Id	Identificador de fila
ProductId	Identificador único del producto
UserId	Identificador único del usuario
ProfileName	Nombre de perfil del usuario
HelpfulnessNumerator	Número de usuarios que consideraron útil la reseña
HelpfulnessDenominator	Número de usuarios que valoraron la utilidad de la reseña (a favor o en contra)
Score	Valoración del producto entre 1 y 5
Time	Marca temporal de la reseña (Unix timestamp)
Summary	Resumen breve de la reseña redactado por el usuario
Text	Cuerpo completo de la reseña

2.3. Características estadísticas básicas

2.3.1. Cifras del corpus

Métrica	Valor
Número de reseñas	568.454
Número de usuarios	256.059
Número de productos	74.258
Usuarios con más de 50 reseñas	260
Mediana de palabras por reseña	56
Período cubierto	Octubre 1999 – Octubre 2012
Número de atributos	10
Rango de la variable Score	1,2,3,4,5 (1 - Negativo) - (5 - Positivo)
Total de palabras en el corpus (con limpieza básica)	45.427.054
Total de palabras únicas en el corpus (con limpieza básica)	240.772

2.4. Fuentes

Recurso	Referencia
Distribución utilizada (Kaggle)	<i>Amazon Fine Food Reviews</i> , Stanford Network Analysis Project. https://www.kaggle.com/datasets/snap/amazon-fine-food-reviews
Distribución original (SNAP)	<i>Web data: Amazon Fine Foods reviews</i> . https://snap.stanford.edu/data/web-FineFoods.html
Referencia académica	McAuley, J. y Leskovec, J. (2013). <i>From amateurs to connoisseurs: modeling the evolution of user expertise through online reviews</i>
Fuente primaria de los datos	Reseñas públicas de usuarios de Amazon.com, categoría de alimentación gourmet.
Licencia	CC0 – Dominio público (según la ficha de datos de Kaggle).

2.5. Tamaño

2.5.1. Tamaño en registros

568 454 documentos cada uno con 10 atributos

2.5.2. Tamaño en disco

El archivo Reviews.csv ocupa un total de 286.97 MB en disco

2.6. Vocabulario

Encontramos 45.427.054 palabras en el corpus tras realizar una limpieza basica, aun no se lematizo, no se quitaron las stopwords, ni se implementó stemming.

Solo 240.772 palabras son unicas en el corpus, dandonos que solo el 0.53% de las palabras del corpus es unica, teniendo sentido ya que todas las reseñas usan un lenguaje similar al estar en un contexto similar.


2.7. Frecuencia de palabras más comunes

2.7.1. Top 10 palabras más frecuentes:

Palabra	Frecuencia
the	1865654
i	1494865
and	1278039
a	1213205
to	1011836
it	914970
of	800656
is	732238
this	669421
for	550523


Como era de esperarse, el top 10 está dominado por stopwords en inglés (the, i, and, a, to...). Ninguna de estas palabras aporta informacion sobre el contenido de las reseñas, lo que confirma que hay que quitarlas para un análisis más elaborado.

2.8. Visualización




Gráfica 1: Gráfico de barras donde muestra la distribución de clases en la variable (Score)

Podemos observar en la gráfica 1 como el dataset cuenta con un claro desbalance entre las clases que cuenta la variable Score, y como el equipo debe de tener este comportamiento en cuenta al entrenar algún modelo.




Gráfica 2: Comparación del top 20 de palabras más encontradas con y sin stopwords

Como lo muestra la gráfica 2, la importancia de eliminar los stopwords es completamente necesario, ya que sin esta podemos observar como siempre las palabras más recurrentes son las que menos contexto dan, o son las que menos describen al documento y le da contexto significativo.



Gráfica 3: Distribucion de la longitud (palabras) de la reseña


Podemos mirae en la gráfica 3 la distribución de la longitud de palabras por reseña y su frecuencia, podemos presenciar cierta asimetria a la derecha en la distribucion, la cual es un comportamiento completamente normal.



Gráfica 4: Gráfica de caja donde compara la cantidad de estrellas que obtuvo una reseña por la cantidad de palabras que la reseña contiene

La gráfica 4 nos brinda el el diagrama de cajas, donde podemos ver la cantidad de palabras por reseña y su respectiva cantidad de estrellas, podemos notar como en general y por muy poca variacion, el diagrama de

cajas que representa las 3 estrellas cuenta con una mediana ligeramente mayor, y con una cola superior más larga en comparación a los demás valores que cuenta la variable Score.



Gráfica 5: Distribucion de la mediana de cantidad de palabras por calificacion

Por último, pero no menos importante, podemos notar la distribución que cuenta la variable Score cuando evaluamos la mediana de cantidad de palabras para cada cantidad de Score. Podemos ver como todas las reseñas con una calificación de 1 a 4 cuenta con una mediana mayor a 61 palabras, mientras que las reseñas con una calificación de 5 estrellas cuenta con una mediana ligeramente menor a 52.5 palabras. Esto puede abrir paso a la siguiente pregunta: ¿Los clientes más satisfechos dejan reseñas más cortas en general?.